Desafio 2

SLAM visual e navegação semântica

Um desafio de pesquisa ligado ao projeto: usar uma câmera RealSense e SLAM visual como fonte de pose do mapa semântico do robô da CPTM, e medir o que isso faz com a navegação semântica ("me leva até o elevador"). É uma lacuna aberta entre duas áreas que andam separadas, e cabe num artigo curto.

O desafio

PERGUNTA CENTRAL

Quando as posições dos objetos do mapa semântico vêm de um SLAM visual com câmera de consumo, e não da pose perfeita do simulador, quanto a navegação semântica perde? E como guardar o mapa para que ele continue certo quando o SLAM corrige a trajetória?

Você escolhe um recorte (as sugestões de lacunas estão abaixo, mas recortes próprios são bem-vindos), implementa em simulação e com a câmera real sobre o sistema que o seu grupo já está construindo, compara com uma linha de base e escreve o resultado como artigo. Mais importante que o resultado ser positivo é você entender e conseguir explicar cada decisão que tomou.

Contexto o que você precisa saber antes de começar

A cadeia da navegação semântica. "Me leva até o elevador" passa por três elos. **Mapear:** a câmera vê o elevador, um detector de vocabulário aberto [1] o reconhece, a profundidade dá a posição em relação à câmera e a pose do robô leva essa posição para o mapa. **Escolher:** um LLM recebe o pedido e a lista de objetos e escolhe o alvo [2]. **Navegar:** a posição do objeto vira objetivo do Nav2 [3]. O primeiro elo só é tão bom quanto a pose do robô no instante em que o objeto foi visto.

SLAM visual e o grafo de poses. Sem pose perfeita, quem estima onde o robô está é o SLAM [4, 5, 6]. Ele guarda quadros-chave como nós de um grafo, ligados por arestas de odometria. A pose deriva aos poucos; quando o robô reconhece um lugar já visitado, uma aresta de **fechamento de laço** entra no grafo e a otimização **reescreve a trajetória inteira**. As poses ficam certas, mas o que foi desenhado sobre as poses antigas pode ficar no lugar errado. As aulas de SLAM são em 15 e 17/12; para este desafio, estude antes (Corke [7], capítulo de localização e mapeamento).

Onde está a lacuna e onde ela não está

EM UMA FRASE

A navegação semântica é avaliada como se a pose fosse perfeita, e o mapeamento semântico com SLAM é avaliado como se a navegação não importasse. O desafio é medir o que acontece no meio.

A premissa é das avaliações. Os métodos de navegação semântica são testados com a pose perfeita do simulador: no desafio de ObjectNav do Habitat, o agente recebe uma câmera RGB-D e um GPS com bússola "noiseless" [8]; Bajpai et al. assumem a pose conhecida e deixam o ruído de sensor como trabalho futuro [9]. O único estudo de ruído que encontramos usa um erro pequeno e simulado e já mostra queda de até 6,1% no sucesso [10]. O problema não é que esses métodos falham: é que **ninguém mediu** quanto eles perdem com o erro de pose de um SLAM visual de verdade.

O que não é a lacuna. Prender o objeto ao grafo de poses, para que ele seja corrigido junto quando o laço fecha, **já foi feito**: o Hydra corrige o grafo de cena no fechamento de laço [11], o FindAnything atualiza os submapas depois de cada otimização [12] e Gallagher et al. fazem isso com ORB-SLAM3 e uma RealSense D435i [13]. Os trabalhos que juntam SLAM visual e mapa semântico medem a qualidade do mapa, não se o robô chega ao objeto certo [14, 12, 13]. Apresentar a correção do objeto como novidade não se sustenta.

O que é a lacuna. Olhar para o fim da cadeia: o robô chega ao elevador certo quando o passageiro pede? A contribuição esperada é uma **medição**: (1) quanto o sucesso da navegação semântica cai conforme o erro de pose cresce; (2) quanto cada forma de guardar o objeto (coordenadas do mundo, preso a um quadro-chave, nó do grafo) recupera dessa queda; (3) tudo isso com câmera de consumo, em ROS 2 e Nav2, onde ninguém testou.

Quando o drift atrapalha. A deriva sozinha não é a vilã principal. Entre dois fechamentos de laço, o objeto e as poses vizinhas derivam juntos, e perto do elevador o mapa fica coerente com o robô. O erro aparece em dois momentos: quando o robô vem de longe, por um caminho com outra deriva, e quando o laço fecha e a trajetória muda, deixando para trás o objeto gravado em coordenadas do mundo. Seu experimento precisa provocar os dois.

Para ir além. Com o objeto como nó do grafo de poses, ele deixa de só ser corrigido e passa a ajudar a corrigir: rever o elevador vira uma restrição a mais na otimização, como um fechamento de laço semântico. Isso também tem literatura, como a relocalização por objetos [15, 16], então não é inédito por si só. O recorte que vale é medir o ganho disso **na navegação**, em corredores e plataformas que se repetem. É um caminho para grupos que queiram ir mais fundo.

O que já existe

situação em outubro de 2026

- **Navegação semântica com pose perfeita.** Bajpai et al. [9] assumem que "the robot pose ... is assumed to be known" e deixam como trabalho futuro o uso no mundo real "under sensor noise". O HM3D-OVON [10] é dos poucos que testam ruído: com odometria de ±7 mm e ±2°, o VLFM [17] perde até 6,1% de sucesso e 5,4% de SPL.
- **Mapa semântico com SLAM e fechamento de laço.** O OVO-SLAM [14] diz ser o primeiro mapeamento de vocabulário aberto online com fechamento de laço (sobre ORB-SLAM2 e Gaussian-SLAM), avaliado por segmentação. O FindAnything [12] atualiza os submapas "after each SLAM optimization, including loop closures", mas não isola o efeito do laço na busca de objetos.
- **O mais perto do nosso cenário.** Gallagher et al. [13] ligaram ORB-SLAM3 ao ConceptGraphs [2] com uma **RealSense D435i** na mão, a cerca de 6 quadros por segundo, atualizando o mapa com as poses otimizadas. Os próprios autores deixam como trabalho futuro tempo real, "Port codebase to ROS architecture to facilitate robot deployment" e uma camada de navegabilidade. O código é aberto: é um bom ponto de partida.
- **Grafos de cena que se deformam.** O Hydra [11] corrige o grafo de cena 3D quando o laço fecha, e o Khronos [18] acrescenta as mudanças da cena no tempo. São pilhas de pesquisa pesadas, com classes fechadas, e não medem navegação a partir de um pedido em linguagem.
- **SLAM avaliado pela navegação.** O TaskSLAM-Bench [19] mede o SLAM pela precisão com que o robô chega ao objetivo, mas o objetivo é geométrico, sem semântica.
- **Ambiente que muda.** O EvoNav-Bench [20] (set/2026) avalia navegação num ambiente que muda, mas o agente recebe a pose do simulador. O DovSG [21] atualiza localmente o grafo de cena em tarefas longas.
- **Embarcado.** O OneMap [22] faz mapeamento de vocabulário aberto em tempo real num Jetson Orin AGX. O cuVSLAM [6] é o SLAM visual acelerado da NVIDIA, com pacote ROS 2.

Sugestões de lacunas escolha uma, combine duas ou proponha outra

Cada sugestão é um recorte possível. As lacunas 1 e 2 se combinam bem num único artigo; a 3 entra naturalmente como eixo de avaliação de qualquer uma.

1 MEDIÇÃO

Quanto custa trocar a pose perfeita pelo SLAM

A navegação semântica costuma ser avaliada com a pose exata do simulador [8, 9]. Os estudos de ruído que existem são pequenos e simulados: com só ±7 mm e ±2° de erro de odometria, o VLFM já perde até 6,1% de sucesso [10]. O TaskSLAM-Bench [19] mede o SLAM pela navegação, mas só com objetivo geométrico, sem semântica.

Pergunta

Como cai o sucesso de "me leva até X" quando a pose vem de um SLAM visual com RealSense, e qual elo da cadeia (mapa, escolha do objeto, navegação) quebra primeiro?

Como medir

Taxa de sucesso e SPL contra o erro de pose (ATE), com três fontes de pose: Gazebo (teto), SLAM visual e odometria com deriva injetada (o erro vira um botão). Erro de posição de cada objeto no mapa.

Leia: [8] [9] [10] [19]

2 REPRESENTAÇÃO

Onde guardar o objeto quando o laço fecha

Quando o SLAM fecha um laço, ele reescreve a trajetória. Um objeto gravado em coordenadas fixas do mundo fica onde foi registrado com a pose errada, e a próxima observação cria uma duplicata. Alguns sistemas já atualizam o mapa com as poses otimizadas [11, 12, 13]: o mecanismo existe, o que falta é medir o efeito dele na navegação.

Pergunta

Guardar o objeto em coordenadas do mundo, preso a um quadro-chave do grafo de poses ou como nó do próprio grafo: qual mantém o mapa consistente, e quanto isso muda o sucesso da navegação?

Como medir

Erro de posição dos objetos e número de duplicatas antes e depois de cada fechamento de laço; sucesso da navegação por representação; custo de atualizar o mapa a cada otimização.

Leia: [11] [12] [13] [14]

3 PLATAFORMA

Mesma câmera, dois corpos

O TurtleBot 3 leva a câmera baixa e anda liso; o Go2 a leva mais alta e balança a cada passo. O mesmo SLAM visual pode se comportar muito diferente nos dois, e o mapa semântico herda esse erro.

Pergunta

Quanto o corpo muda o erro do SLAM visual e a qualidade do mapa semântico? A IMU da câmera compensa o balanço do Go2? Um mapa feito por um robô serve para o outro navegar?

Como medir

ATE/RPE e perdas de rastreamento por robô, com e sem IMU; erro dos objetos; sucesso da navegação com o mapa do próprio robô e com o mapa do outro.

Leia: [4] [5] [6]

4 LINGUAGEM

O LLM sabe que o mapa pode estar errado?

Quem escolhe o objeto a partir do pedido é o LLM, e ele costuma receber a lista de objetos como se fosse verdade. Mas cada objeto tem uma confiança de detecção, um número de observações e uma idade, e pode haver dois "elevadores" no mapa.

Pergunta

Entregar ao LLM a incerteza de cada objeto (e não só o rótulo) reduz a escolha do alvo errado? Ele aprende a perguntar ao passageiro quando o mapa é ambíguo?

Como medir

Taxa de alvo errado, perguntas feitas ao passageiro (e quantas eram necessárias), sucesso da navegação, com e sem a incerteza no prompt.

Leia: [2] [9] [22]

5 MUDANÇA

O mapa envelhece

Numa estação, pessoas passam, quiosques mudam de lugar e tapumes aparecem. Os sistemas de mapeamento semântico com SLAM ainda assumem a cena estática: tratar objetos dinâmicos e pessoas "remains an open challenge" [12]. Os benchmarks de ambiente que muda dão ao agente a pose do simulador [20].

Pergunta

Como separar o que é fixo, o que muda devagar e o que se move, para que pessoas não contaminem o SLAM e objetos que sumiram expirem do mapa, sem refazê-lo do zero?

Como medir

Sucesso em visitas repetidas depois de mudar o cenário, objetos fantasmas no mapa, erro do SLAM com e sem pessoas filtradas.

Leia: [12] [18] [20] [21]

Como avaliar o seu sistema

Qualquer que seja o recorte, o artigo precisa de uma comparação justa. Algumas peças que se repetem:

Peça	Sugestão
Linha de base	A pose do Gazebo (o teto: é assim que a literatura avalia); a odometria pura (o piso); o mapa em coordenadas fixas do mundo.
Cenários	Em simulação, um mundo de estação (mezanino, corredor, plataforma) com alvos como elevador, bilheteria, catraca, escada rolante e placa de plataforma. No mundo real, um corredor ou hall do campus com uma volta fechada, para forçar o fechamento de laço. Repita cada pedido várias vezes.
Verdade de referência	No Gazebo, a pose e a posição de cada objeto são conhecidas. No mundo real, marque os alvos com AprilTags ou meça com trena a partir de um referencial no chão.
Métricas	Erro de trajetória (ATE/RPE, com a ferramenta evo); erro de posição dos objetos, duplicatas e objetos perdidos; sucesso (chegar a menos de 1 m do alvo certo), SPL, alvo errado; latência e quadros por segundo no notebook e no Jetson.
Ablação	Tire uma peça de cada vez (fechamento de laço, IMU, atualização do mapa após a otimização, detecção em todo quadro ou só nos quadros-chave) e mostre o efeito.

Ferramentas e recursos

- **Câmera**: Intel RealSense da série D400, com o pacote `realsense2_camera` do ROS 2. Confira o modelo antes de começar: só os modelos com IMU (como D435i e D455) permitem SLAM visual-inercial.
- **Robôs**: TurtleBot 3 e Unitree Go2 (o Go2 é escasso: combine as janelas de uso cedo). Processamento no notebook ou num Jetson.
- **SLAM visual**: RTAB-Map [5] (pacote ROS 2 pronto, expõe o grafo otimizado), ORB-SLAM3 [4] e Isaac ROS Visual SLAM (cuVSLAM [6], exige GPU NVIDIA).
- **Mapa semântico**: YOLO-World [1] para detectar por nome; ConceptGraphs [2] e o código de Gallagher et al. [13] como ponto de partida.
- **Avaliação**: evo (github.com/MichaelGrupp/evo) para ATE/RPE; apriltag_ros para a verdade de referência.

Cuidados

- A área anda rápido: refaça a busca no arXiv ("open-vocabulary mapping" + "loop closure", "object goal navigation" + "pose noise") no início e antes de entregar.
- SLAM visual baseado em pontos precisa de textura: um mundo do Gazebo com paredes lisas pode não fechar laço nenhum. Texturize o mundo e teste isso na primeira semana.
- Grave só em espaços do campus, sem filmar pessoas sem consentimento; nada de gravações em estações da CPTM nem de materiais internos do parceiro no artigo ou em repositórios públicos.
- Resultado negativo também é resultado: se o SLAM visual não atrapalhar a navegação semântica, mostrar por quê é uma contribuição.
- Use IA para estudar e programar, mas você precisa conseguir explicar cada parte do que entregou.

Referências

[1] CHENG, T. et al. YOLO-World: Real-Time Open-Vocabulary Object Detection. In: IEEE/CVF CVPR, 2024. arXiv:2401.17270.

[2] GU, Q. et al. ConceptGraphs: Open-Vocabulary 3D Scene Graphs for Perception and Planning. In: IEEE ICRA, 2024. arXiv:2309.16650.

[3] MACENSKI, S. et al. The Marathon 2: A Navigation System. In: IEEE/RSJ IROS, 2020. arXiv:2003.00368.

[4] CAMPOS, C. et al. ORB-SLAM3: An Accurate Open-Source Library for Visual, Visual-Inertial and Multi-Map SLAM. IEEE Transactions on Robotics, 2021. arXiv:2007.11898.

[5] LABBÉ, M.; MICHAUD, F. RTAB-Map as an Open-Source Lidar and Visual SLAM Library for Large-Scale and Long-Term Online Operation. Journal of Field Robotics, 2019.

[6] KOROVKO, A. et al. cuVSLAM: CUDA Accelerated Visual Odometry and Mapping. arXiv:2506.04359, 2025.

[7] CORKE, P. Robotics, Vision and Control: Fundamental Algorithms in Python. 3. ed. Springer, 2023.

[8] HABITAT. Habitat Navigation Challenge 2023. 2023. https://aihabitat.org/challenge/2023/

[9] BAJPAI, U.; RÜCKIN, J.; STACHNISS, C.; POPOVIC, M. Uncertainty-Informed Active Perception for Open Vocabulary Object Goal Navigation. arXiv:2506.13367, 2025.

[10] YOKOYAMA, N. et al. HM3D-OVON: A Dataset and Benchmark for Open-Vocabulary Object Goal Navigation. arXiv:2409.14296, 2024.

[11] HUGHES, N.; CHANG, Y.; CARLONE, L. Hydra: A Real-time Spatial Perception System for 3D Scene Graph Construction and Optimization. In: Robotics: Science and Systems, 2022. arXiv:2201.13360.

[12] LAINA, S. B. et al. FindAnything: Open-Vocabulary and Object-Centric Mapping for Robot Exploration in Any Environment. arXiv:2504.08603, 2025.

[13] GALLAGHER, F.; COGNETTI, M.; McDONALD, J. B. Towards Online Open-vocabulary 3D Scene Graphs (pôster). 2025. https://europe.naverlabs.com/wp-content/uploads/2025/10/Towards-Online-Open-vocabulary-3D-Scene-Graphs1.pdf

[14] MARTINS, T. B.; OSWALD, M. R.; CIVERA, J. Open-Vocabulary Online Semantic Mapping for SLAM. IEEE Robotics and Automation Letters, 2025. arXiv:2411.15043.

[15] WANG, Y.; JIANG, C.; CHEN, X. GOReloc: Graph-based Object-Level Relocalization for Visual SLAM. IEEE Robotics and Automation Letters, 2024. arXiv:2408.07917.

[16] CUI, Z. et al. Compact Object-Level Representations with Open-Vocabulary Understanding for Indoor Visual Relocalization. IEEE Robotics and Automation Letters, 2026. arXiv:2606.24767.

[17] YOKOYAMA, N. et al. VLFM: Vision-Language Frontier Maps for Zero-Shot Semantic Navigation. In: IEEE ICRA, 2024. arXiv:2312.03275.

[18] SCHMID, L.; ABATE, M.; CHANG, Y.; CARLONE, L. Khronos: A Unified Approach for Spatio-Temporal Metric-Semantic SLAM in Dynamic Environments. In: Robotics: Science and Systems, 2024. arXiv:2402.13817.

[19] DU, Y.; FENG, S.; CORT, C. G.; VELA, P. A. Task-driven SLAM Benchmarking For Robot Navigation. In: IEEE/RSJ IROS, 2025. arXiv:2409.16573.

[20] WANG, X. et al. EvoNav-Bench: Benchmarking Lifelong Navigation in Evolving Environments. arXiv:2609.08292, 2026.

[21] YAN, Z. et al. Dynamic Open-Vocabulary 3D Scene Graphs for Long-term Language-Guided Mobile Manipulation. IEEE Robotics and Automation Letters, 2025. arXiv:2410.11989.

[22] BUSCH, F. L. et al. One Map to Find Them All: Real-time Open-Vocabulary Mapping for Zero-shot Multi-Object Navigation. arXiv:2409.11764, 2024.