Desafio 3

Uma frota, um atendente

Um desafio de pesquisa ligado ao projeto: em vez de um robô, a estação tem uma frota pequena e heterogênea (TurtleBot 3, Go2 e o tablet) que, para o passageiro, precisa funcionar como um único atendente. É um tema de sistemas multirrobô em que os trabalhos com modelos de linguagem têm meses, e cabe num artigo curto.

O desafio

PERGUNTA CENTRAL

Como dividir o atendimento de uma estação (pedidos falados que chegam a qualquer momento, conduções de passageiros, emergências) entre robôs com corpos diferentes, de modo que a frota atenda mais rápido e com mais segurança do que robôs independentes, usando o modelo de linguagem só onde ele ajuda?

Você escolhe um recorte (as sugestões de lacunas estão abaixo, mas recortes próprios são bem-vindos), implementa no simulador sobre o sistema que o seu grupo já está construindo, compara com uma linha de base e escreve o resultado como artigo. Mais importante que o resultado ser positivo é você entender e conseguir explicar cada decisão que tomou.

Contexto o que você precisa saber antes de começar

Três problemas clássicos. Um sistema multirrobô precisa decidir quem faz o quê (alocação de tarefas, MRTA [1]), por onde cada um vai sem colidir nem travar os outros (planejamento de caminhos multiagente, MAPF [2]) e o que os robôs contam uns aos outros (comunicação e cooperação). Os três se apoiam em grafos: a alocação é um emparelhamento entre robôs e tarefas, resolvido de forma ótima pelo algoritmo húngaro [3], e o MAPF é busca num grafo que se expande no tempo.

Na prática, em ROS 2. Cada robô roda o seu Nav2 [4] num namespace próprio. Acima deles, o Open-RMF [5] despacha tarefas por leilão entre frotas e reserva trechos de caminho, portas e elevadores. É uma referência de arquitetura, não a resposta pronta: foi pensado para robôs industriais e de entrega, não para robôs que conduzem pessoas.

E os modelos de linguagem. LLMs já decompõem uma instrução num plano para vários robôs [6, 7], mas otimizam mal quando precisam resolver o problema combinatório sozinhos [8]. A tendência recente é dividir o trabalho: o LLM traduz o pedido para uma forma estruturada e um otimizador clássico decide [9, 10]. Os problemas em aberto são latência, alucinação e falta de avaliações comparáveis [11].

A diferença que torna o tema novo. Quase toda a literatura de multirrobô com LLM é **doméstica e episódica**: uma instrução, um plano, nenhuma pessoa no caminho. Na estação, os pedidos chegam de pessoas diferentes ao longo do tempo, a condução prende uma pessoa ao robô, a emergência passa na frente de tudo e os corpos têm capacidades diferentes.

Desafio 3 · Uma frota, um atendente

O que já existe situação em outubro de 2026

- **LLM planejando para equipes heterogêneas.** SMART-LLM [6] e COHERENT [7] distribuem uma tarefa longa entre robôs diferentes; EMOS [12] gera um "currículo" de cada robô a partir da sua descrição (URDF) para saber o que cada corpo consegue; CoMuRoS [13] replaneja por evento em ROS 2. Todos tratam um episódio por vez, sem fila de pedidos e sem pessoas no ambiente.
- **LLM traduz, otimizador decide.** FLEET [9] gera um problema de programação inteira e minimiza o tempo total de um lote de instruções; OSDAG [10] chama o LLM uma vez e despacha online um grafo de tarefas fixo; DEXTER-LLM [14] aloca tarefas que surgem durante uma inspeção. Nenhum trata pedidos independentes de pessoas diferentes, com prioridade.
- **Capacidade de cada corpo.** Weiner e Korpan [15] (20/10/2026) mostram que dez formas de medir a adequação robô-tarefa discordam entre si e que a nota dada por um LLM muda com a redação. KGLAMP [16] replaneja a partir de um grafo de conhecimento, mas a alcançabilidade é simbólica, não vem do mapa.
- **Tráfego.** Bonetti et al. [17] coordenam veículos de tamanhos diferentes em corredores estreitos, mas numa fábrica sem pessoas. MAPF entre agentes não controláveis, com garantia estatística, existe em grade [18]. TRACER [19] mostra que o efeito de vários robôs sobre as pessoas não é a soma dos efeitos de cada um.
- **Guiar pessoas com vários robôs.** Fu et al. [20] distribuem visitantes de museu entre robôs-guia, em lote e sem resolver conflitos entre os pares. O trabalho mais recente de condução [21] usa um único robô.
- **Passar a pessoa de um robô a outro.** Já foi estudado em campo [22], sem LLM e sem contexto compartilhado entre os robôs. Entre agentes LLM de texto, o contexto diverge e gera respostas contraditórias [23, 24]; ninguém mediu isso com robôs atendendo o público.

Sugestões de lacunas escolha uma, combine duas ou proponha outra

Cada sugestão é um recorte possível. As lacunas 1 e 2 se combinam bem (a emergência é um pedido com prioridade máxima), assim como a 4 e a 5 (o que a frota sabe e como compartilha). Outros recortes: posicionar os robôs ociosos conforme a demanda do horário de pico [25], ou fundir os mapas do TurtleBot 3 e do Go2, que enxergam a estação de alturas diferentes (conversa com o desafio 2).

1 ALOCAÇÃO

Pedidos falados chegando a qualquer momento

Passageiros fazem pedidos ao longo do tempo, a qualquer robô ou ao tablet. Uma divisão possível: o LLM transforma a fala numa tarefa estruturada (tipo, destino, prioridade, restrição de mobilidade, duração provável) e um alocador clássico (algoritmo húngaro [3] ou leilão) redistribui a frota a cada pedido novo.

Pergunta

Essa divisão atende mais rápido e erra menos que um LLM escolhendo diretamente qual robô atende [6, 7]? Pistas na fala ("estou de muleta", "estou com criança") melhoram a estimativa da duração da condução e, com ela, a alocação dos pedidos seguintes?

Como medir

Tempo até o atendimento (média e p95) por tipo de pedido, alocações inválidas (robô que não consegue fazer a tarefa), acurácia da extração, chamadas ao LLM e latência. Linhas de base: LLM alocando sozinho, robô livre mais próximo e um oráculo com extração perfeita.

Leia: [8] [9] [10] [14] [26]

Desafio 3 · Uma frota, um atendente

2 EMERGÊNCIA

Mal súbito no meio de uma condução

Um passageiro passa mal enquanto todos os robôs estão ocupados. Interromper o robô mais próximo deixa sozinha a pessoa que ele conduz; esperar um robô livre atrasa o socorro; outro robô ou o tablet pode assumir a condução interrompida. E quem fica com a vítima, quem vai buscar a segurança da estação (SSO)?

Pergunta

Qual política de preempção e divisão de papéis minimiza o tempo até o socorro sem abandonar ninguém? Um LLM que distribui os papéis a partir das capacidades de cada corpo [12] faz melhor ou pior que uma regra fixa ou um leilão?

Como medir

Tempo até a SSO chegar à vítima, tempo em que a vítima ficou sem nenhum robô (meta: zero), atraso causado nas conduções, conduções interrompidas, papéis corretos em variações (robô ocupado, bateria baixa, Go2 fora de serviço).

Leia: [12] [15] [20] [22]

3 TRÁFEGO

O par robô e passageiro no corredor

Durante a condução, o robô e a pessoa se movem juntos: ocupam mais espaço que o robô sozinho e andam no ritmo de quem é conduzido. Num corredor estreito de plataforma, com pedestres, dois pares em sentidos opostos podem travar um ao outro.

Pergunta

Tratar o par como um agente heterogêneo no grafo da estação (largura e velocidade próprias, capacidade por aresta, reserva de corredor) reduz travamentos e espera em relação a cada robô usando o seu Nav2 sozinho? Quanto a frota atrapalha o fluxo de pedestres?

Como medir

Travamentos por hora, espera média, tempo de condução, distância e atraso impostos aos pedestres (métricas do HuNavSim), por densidade de pessoas. Linhas de base: Nav2 independente em cada robô e reserva de arestas por ordem de chegada.

Leia: [17] [18] [19] [27] [28] [29]

4 CONTINUIDADE

Uma frota que se apresenta como um só atendente

O robô do mezanino entrega o passageiro ao robô da plataforma, ou a mesma pessoa fala com dois robôs. As pessoas confiam mais quando é "o mesmo agente" mudando de corpo do que quando outro robô assume [30], mas isso exige que o contexto (quem é a pessoa, o que pediu, o que já foi dito) passe de um robô para o outro e que eles não se contradigam quando a estação muda (plataforma interditada, elevador parado).

Pergunta

Que formato de contexto transferido (resumo em texto, estado estruturado, histórico completo) preserva melhor o pedido com menor custo? Um estado compartilhado reduz as respostas contraditórias em relação a robôs independentes ou a mensagens livres entre eles?

Como medir

Campos do pedido preservados depois da passagem, reperguntas ao passageiro, contradições entre robôs (conferidas contra o estado verdadeiro), tempo até uma mudança chegar a todos, tokens e latência. Linhas de base: passagem sem contexto e robôs independentes.

Leia: [22] [23] [24] [30] [31] [32] [33]

5 CONHECIMENTO

O que um robô descobre, a frota sabe, conforme o corpo

Um robô encontra a escada interditada ou o elevador parado. O evento só importa para quem usaria aquela passagem: escada bloqueada muda a rota do Go2, não a do TurtleBot 3, que nunca subiria por ela. Antes de despachar um robô, também é preciso conferir se ele de fato consegue chegar.

Pergunta

Propagar eventos no grafo da estação filtrados pelo corpo de cada robô, e verificar cada atribuição com o planejador do Nav2 do próprio robô, reduz tarefas inviáveis e distância desperdiçada? Quanto isso custa em latência?

Como medir

Tempo até a frota inteira replanejar, distância desperdiçada, tarefas que falham, atribuições inviáveis aceitas, mensagens trocadas, falsos positivos (bloqueio que já acabou). Linhas de base: cada robô descobre sozinho, todos bloqueiam tudo, LLM sem verificador.

Leia: [12] [15] [16] [34] [35] [36]

Como avaliar o seu sistema

Qualquer que seja o recorte, o artigo precisa de uma comparação justa. Algumas peças que se repetem:

Peça	Sugestão
Linha de base	Robôs independentes, cada um com o seu Nav2 atendendo quem chegar; regra gulosa (robô livre mais próximo); LLM decidindo sozinho.
Cenários	Fluxo de pedidos com taxa de chegada variável (vale e chegada de trem), emergência durante conduções, corredor estreito com pedestres, escada ou elevador interditados, um robô que sai de serviço no meio. Repita cada um várias vezes, com sementes diferentes.
Métricas	Espera do passageiro (média e p95), pedidos atendidos por hora, tempo até o socorro, travamentos, tarefas inviáveis, chamadas ao LLM, latência e custo.

Escala	Três a cinco robôs bastam. Mostre como as métricas mudam com o número de robôs e com a taxa de pedidos.
Ablação	Tire uma peça de cada vez (o otimizador, o filtro por corpo, o estado compartilhado) e mostre o efeito.

Ferramentas e recursos

- **Nav2 com vários robôs** (docs.nav2.org): cada robô num namespace próprio; o pacote nav2_bringup traz um exemplo de simulação com vários TurtleBot 3.
- **Open-RMF** [5]: despacho por leilão, reserva de tráfego, portas e elevadores. Leia como referência de arquitetura ou use como linha de base; integrá-lo, sozinho, é engenharia, não contribuição.
- **HuNavSim** [37]: pedestres simulados para ROS 2 e Gazebo, com métricas de navegação social.
- **Alocação e caminhos**: o algoritmo húngaro está pronto em scipy.optimize.linear_sum_assignment. Para caminhos, comece por planejamento com prioridade antes de tentar métodos ótimos: com agentes grandes, o ótimo é intratável [29].
- **O tablet**: um nó ROS 2 sem base móvel, com as mesmas interfaces dos robôs. É um membro da frota que entende pedidos e despacha, mas não conduz.
- **LLM**: use saída estruturada (JSON com esquema) para os pedidos e as mensagens entre robôs. Não é preciso treinar nada.

Cuidados

- A área anda rápido: vários trabalhos citados têm semanas. Refaça a busca no arXiv ("multi-robot" + "LLM", "task allocation", "multi-agent path finding" + "human") no início e antes de entregar. O workshop FM-MRS (Foundation Models for Multi-Robot Systems) do IROS 2026 é um bom lugar para acompanhar.
- Comparar "húngaro contra guloso", sozinho, não é contribuição. A novidade está no que a estação traz: pessoas presas ao robô, prioridades, corpos diferentes, fala.
- Resultado negativo também é resultado: se a regra fixa ganhar do LLM, mostrar quando e por quê é uma contribuição.
- Simular vários robôs pesa: comece com dois e cresça.
- Use IA para estudar e programar, mas você precisa conseguir explicar cada parte do que entregou.
- Não use materiais internos da CPTM no artigo nem em repositórios públicos.

Referências

[1] GERKEY, B. P.; MATARI, M. J. A Formal Analysis and Taxonomy of Task Allocation in Multi-Robot Systems. The International Journal of Robotics Research, v. 23, n. 9, p. 939-954, 2004.

[2] STERN, R. et al. Multi-Agent Pathfinding: Definitions, Variants, and Benchmarks. In: SoCS, 2019. arXiv:1906.08291.

[3] KUHN, H. W. The Hungarian Method for the Assignment Problem. Naval Research Logistics Quarterly, v. 2, p. 83-97, 1955.

[4] MACENSKI, S. et al. The Marathon 2: A Navigation System. In: IEEE/RSJ IROS, 2020. arXiv:2003.00368.

[5] OPEN ROBOTICS. Programming Multiple Robots with ROS 2 (Open-RMF). https://osrf.github.io/ros2multirobotbook/

[6] KANNAN, S. S.; VENKATESH, V. L. N.; MIN, B.-C. SMART-LLM: Smart Multi-Agent Robot Task Planning using Large Language Models. In: IEEE/RSJ IROS, 2024. arXiv:2309.10062.

[7] LIU, K. et al. COHERENT: Collaboration of Heterogeneous Multi-Robot System with Large Language Models. In: IEEE ICRA, 2025. arXiv:2409.15146.

[8] HUANG, Z.; SHI, G.; SUKHATME, G. S. Can Large Language Models Solve Robot Routing? In: ISRR, 2024. arXiv:2403.10795.

[9] RIVERA, C. et al. FLEET: Formal Language-Grounded Scheduling for Heterogeneous Robot Teams. arXiv:2510.07417, 2025.

[10] NGUYEN CANH, T. et al. OSDAG: Online Scheduling for Efficient Multi-Robot Collaboration. arXiv:2606.15255, 2026.

[11] LI, P. et al. Large Language Models for Multi-Robot Systems: A Survey. arXiv:2502.03814, 2025.

[12] CHEN, J. et al. EMOS: Embodiment-aware Heterogeneous Multi-robot Operating System with LLM Agents. In: ICLR, 2025. arXiv:2410.22662.

[13] BORATE, S. et al. LLM-Based Generalizable Hierarchical Task Planning and Execution for Heterogeneous Robot Teams with Event-Driven Replanning. arXiv:2511.22354, 2025.

[14] ZHU, Y. et al. DEXTER-LLM: Dynamic and Explainable Coordination of Multi-Robot Systems in Unknown Environments via Large Language Models. arXiv:2508.14387, 2025.

[15] WEINER, D.; KORPAN, R. Robot-Task Suitability in Heterogeneous Multi-Robot Task Allocation. In: Workshop FM-MRS, IEEE/RSJ IROS, 2026. arXiv:2610.27504.

[16] SHEK, C. L. et al. KGLAMP: Knowledge Graph-guided Language model for Adaptive Multi-robot Planning and Replanning. arXiv:2602.04129, 2026.

[17] BONETTI, A. et al. A Traffic Management System for Large and Heterogeneous Vehicles in Narrow Industrial Environments. The International Journal of Robotics Research, 2026. arXiv:2609.10400.

[18] STRAWN, K. J. et al. Multi-Agent Path Finding Among Dynamic Uncontrollable Agents with Statistical Safety Guarantees. arXiv:2507.22282, 2025.

[19] HU, L. et al. TRACER: Adaptive Multi-Robot Social Navigation via Joint Human-Response Prediction and Interaction-Aware Replanning. arXiv:2609.18776, 2026.

[20] FU, B. et al. Simultaneous Human-robot Matching and Routing for Multi-robot Tour Guiding under Time Uncertainty. ASME Journal of Autonomous Vehicles and Systems, 2022. arXiv:2201.10635.

[21] SHREE, V.; NINO, J. Social Navigation for Tour-guide Robot. In: Workshop on Social Robot Navigation, IEEE/RSJ IROS, 2026. arXiv:2610.05455.

[22] TAN, X. Z.; CARTER, E. J.; STEINFELD, A. Person Transfer in the Field: Examining Real World Sequential Human-Robot Interaction Between Two Robots. In: IEEE RO-MAN, 2024. arXiv:2406.06904.

[23] RODRIGUES, C. Hallucination as Context Drift: Synchronization Protocols for Multi-Agent LLM Systems. arXiv:2606.21666, 2026.

[24] CEMRI, M. et al. Why Do Multi-Agent LLM Systems Fail? arXiv:2503.13657, 2025.

[25] CARAGIANNIS, I. et al. The Robotaxi Placement Problem: Minimizing Expected ETA for Stochastic Demand. arXiv:2605.15745, 2026.

[26] KAZEMI ESKERI, M. et al. Efficient Human-Aware Task Allocation for Multi-Robot Systems in Shared Environments. In: IEEE/RSJ IROS, 2025. arXiv:2508.19731.

[27] CAO, B. From Real-Time Planning to Reliable Execution: Scalable Coordination for Heterogeneous Multi-Robot Fleets in Industrial Environments. arXiv:2607.00591, 2026.

[28] FU, B. et al. Human-robot Matching and Routing for Multi-robot Tour Guiding under Time Uncertainty. Workshop ICRA 2022. arXiv:2309.15373.

[29] AGAFONOV, A.; YAKOVLEV, K. Multi-Agent Path Finding For Large Agents Is Intractable. arXiv:2505.10387, 2025.

[30] REIG, S.; CARTER, E. J.; FONG, T.; FORLIZZI, J.; STEINFELD, A. Flailing, Hailing, Prevailing: Perceptions of Multi-Robot Failure Recovery Strategies. In: ACM/IEEE HRI, 2021.

[31] TAN, X. Z.; LURIA, M.; STEINFELD, A.; FORLIZZI, J. Charting Sequential Person Transfers Between Devices, Agents, and Robots. In: ACM/IEEE HRI, 2021.

[32] LIU, X. et al. Unified Agent: Managing Interactions across Devices. arXiv:2608.05729, 2026.

[33] HUANG, Z. et al. Propagating Unsafe Actions in LLM Controlled Multi-Robot Collaboration via Single Robot Compromise. In: IJCAI, 2026. arXiv:2605.15641.

[34] RAVANKAR, A. et al. Symbiotic Navigation in Multi-Robot Systems with Remote Obstacle Knowledge Sharing. Sensors, v. 17, n. 7, 2017.

[35] KHATANA, V. et al. Verifier-Mediated Multi-LLM Coordination for Multi-Robot Path Planning. In: Workshop FM-MRS, IEEE/RSJ IROS, 2026. arXiv:2610.12761.

[36] ABAZA, B. F.; STAICU, A.-A.; DOICIN, C. V. A Semantic Autonomy Framework for VLM-Integrated Indoor Mobile Robots: Hybrid Deterministic Reasoning and Cross-Robot Adaptive Memory. arXiv:2605.02525, 2026.

[37] ESCUDERO-JIMÉNEZ, M. et al. HuNavSim 2.0: An Enhanced Human Navigation Simulator for Human-Aware Robot Navigation. In: ROBOT 2025. arXiv:2507.17317.